

FLOPs

Для свёртки

7.7

stride=2

, которая применяется

изображению в 2 раза

$$S \rightarrow \frac{S}{2}$$

$$\left(\frac{S}{2}\right)^2 \text{ точек зрения}$$

определено по размеру канала: $kernel_size \cdot kernel_size$

для свёртки 7.7

$$\text{умножение } 7.7 = 49$$

$$\text{сложение } 7.7 - 1 = 48 \approx 49$$

$$\left. \begin{array}{l} \text{умножение } 7.7 = 49 \\ \text{сложение } 7.7 - 1 = 48 \approx 49 \end{array} \right\} \approx 2 \cdot kernel_size^2 \cdot \left(\frac{S}{2}\right)^2$$

потому что количество сложений равно количеству умножений:

$$dim_in \cdot \left(\frac{S}{2}\right)^2$$

$$\left. \begin{array}{l} \text{для всех каналов } dim_in \cdot \left(\frac{S}{2}\right)^2 \\ dim_in \cdot 2 \cdot kernel_size^2 \cdot \left(\frac{S}{2}\right)^2 \end{array} \right\} \Rightarrow$$

$$\Rightarrow \text{FLOPs} \left(\begin{array}{l} \text{conv} \\ \text{kernel-size} \\ \text{stride}=2 \\ \text{dim-in} \\ \text{dim-out} \end{array} \right) =$$

$$= dim_out \cdot dim_in \cdot \left(\frac{S}{2}\right)^2 \left(2 \cdot kernel_size^2 + 1 \right)$$

Дад maxpooling $stride=2$ (в 2 раза уменьшает image)

3×3
kernel-size = 3

$p=1$

$$S \rightarrow S/2$$

выходных значений $\left(\frac{S}{2}\right)^2$

выбор максимумов: kernel-size² элементов $\text{out} \left(\frac{S}{2}\right)^2$

$$\rightarrow \text{FLOPS} \left(\begin{array}{l} \text{func maxpool } 3 \times 3 \\ \text{stride} = 2 \\ \text{padding} = 1 \\ \text{dim_in} = 32 \\ \text{dim_out} = 32 \end{array} \right) \approx \text{kernel-size}^2 \cdot \left(\frac{S}{2}\right)^2 \cdot \text{dim_out}$$

conv

③

(kernel-size $\times$ kernel-size) stride = 1

без промежуточных padding.

$S \rightarrow S$ image size,

то есть S^2 умножений гарантированно, то есть

$$\text{FLOPS} \approx \text{dim-out} \cdot \text{dim-in} \cdot S^2 \cdot (2 \cdot \text{kernel-size}^2 + 1)$$

Sum global avg pool

(4)

$$512 \times \frac{S}{16} \times \frac{S}{16} \rightarrow 512$$

$$\text{FLOPs} \left(512 \cdot \frac{S}{16} \cdot \frac{S}{16} \right) = 512 \cdot \frac{S}{16} \cdot \frac{S}{16}$$

Linear 2D матричное умножение:

$$512 \rightarrow 256$$

512 умножают на 256 весов:

$$\begin{matrix} (1, 512) @ (1, 256) \\ (512, 1) @ (512, 256) \end{matrix} \rightarrow W$$

$\Downarrow$

$$\text{FLOPs}(\text{2D матричное умножение}) : 2 \cdot 512 \cdot 1 \cdot 256 = 512 \cdot 512$$

$$\text{FLOPs}(256 \rightarrow 100) = 2 \cdot 256 \cdot 100$$

Relu усреднением (1 FLOPs)

Memory

$$\begin{aligned} \text{Conv}(n \times n) &\rightarrow \text{weights} = \underline{n \times n \times C_{in} \times C_{out}} \\ \text{channels}_{input} &= C_{in} \\ \text{channels}_{output} &= C_{out} \end{aligned}$$

maxpool, relu, GAP } не требуют памяти, если исходная память
уже ~~memory~~ ~~2 out memory~~
memory = out_tensor

Linear:

хранит веса $W.shape = [linear_{in}, linear_{out}]$

Тензоры: ~~$[B, S]$~~ $[B, (3), \frac{S}{4}, \frac{S}{4}]$ channels

После свертки:

~~$[B, \frac{S}{4}, \frac{S}{4}]$~~ $[B, \downarrow, 32, \frac{S}{4}, \frac{S}{4}]$

и т.д. ...

+

суммирует тензоры

Bytes moved: (произведено умножение на FP32 - 32 бита)

для conv $n \times n$ stride - шаг сдвига
каналов - каналов
batch B

Размер изображения S

bytes moved: чтение S, чтение kernel, запись результата

$B \times n \times n \times \text{channels}$ - чтение kernel

$B \times S \times S \times \text{channels}$ - чтение image

$B \times \frac{S}{\text{stride}} \times \frac{S}{\text{stride}} \times \text{channels-out}$ - запись результата

} sum

для Linear: B - batch.

Array [1, ~~input-shape~~] Weights (^{input-shape}~~input-shape~~, output-shape)

зане чтение vecs:

$B \cdot \text{input-shape} \cdot \text{output-shape}$

чтение input:

$B \cdot \text{input-shape}$

запись output:

$B \cdot \text{output-shape}$

} sum

maxpool:

время вычисления:

$$B \times S \times S \times \text{channels}$$

запись результата

$$B \times \frac{S}{2} \times \frac{S}{2} \times \text{channels}$$

} sum

global avg pool:

время:

$$B \times S \times S \times \text{channels}$$

запись:

$$B \times \text{channels} \times 1$$

} sum

relu:

время:

$$B \times S \times S \times \text{channels}$$

запись:

$$B \times S \times S \times \text{channels}$$

} sum

Latency:

Zero Latency (1 ops/byte) Byte operations

max

$$\max \left(\frac{\text{Bytes Moved}(S, B)}{\text{maximum bandwidth GPU}}, \frac{\text{FLOPS}(S, B)}{\text{peak Flops GPU}} \right)$$

GPU - Tesla T4

Interconnect bandwidth - ~~8.1 TFLOPS~~ 32 GB/sec

peak FLOPS (single precision) - 8.1 TFLOPS

Energy

$$\frac{\text{FLOPS}(S, B)}{\text{energy to flops}} + \frac{\text{Bytes Moved}(S, B)}{\text{energy to bytes moved}}$$

energy to flops

energy to bytes moved

↓
approx

Fp32 add + mult/div $\approx 4 \text{ pJ}$

32 KB $\sim 20 \text{ pJ}$